Universidad autónoma de Yucatán

Facultad de Matemáticas

Licenciatura en Ingeniería en Computación

Quinto Semestre

Inteligencia Artificial

Reporte - Perceptrón multicapa Ejercicio 1

Docente:Victor Emanuel Uc Cetina

Fecha de entrega: Mérida, Yucatán a, Lunes 05 de octubre del 2026

Nombre:

- López Carrillo José Luis



REPORTE

Ejercicio 1 : Más capas en el perceptrón multicapa (Iris)

1. ¿Bajó más el error al añadir dos capas, o se estancó / empeoró? ¿Igual en NumPy y Keras? Al usar 3 capas el error empeoró bastante y se estancó. Intuitivamente meterle más neuronas y capas a la red haria que aprenda mejor , pero pasó lo contrario . La curva de pérdida casi casi se aplano al principio y de ahí no bajo nada. Lo más interesante es que esto se repite de forma casi idéntica tanto en la implementación hecha a mano en numpy usando “keras.Sequential”. En ambas versiones el modelo profundo demostró ser mucho menos eficiente que el original de una sola capa oculta.

2.¿Las curvas de la notebook 01 y de Keras se parecen con la misma topología? Si no, ¿qué diferencias de implementación podrían explicarlo (orden de los datos, inicialización, vectorización, etc.)?

Tienen la misma tendencia general al descender , pero no son exactos a pesar de tener la misma arquitectura de 4 x 3 x 3. Analizándolo, esto pasa porque keras nos hace el paro optimizado detalles técnicos por debajo del agua que a mano no se configuraron igual . Las diferencias más notorias en las gráficas vienen de factores de implementación como :

- **Inicialización de los pesos:** Keras usa algoritmos más avanzados por default (como Xavier/Glorot), mientras que a mano solemos meter un random más simple.
- **Orden de los datos:** Keras gestiona de manera más robusta el barajeo (shuffling) en cada época durante el entrenamiento.
- **Vectorización:** La manera en que Keras y TensorFlow manejan el cálculo matricial a bajo nivel hace que el descenso se note ligeramente más fluido que en los ciclos armados a mano.

3. Con sigmoides apiladas y MSE, ¿tiene sentido que una red más profunda no aprenda mejor en Iris? Relacionalo con lo que viste en las gráficas.

Tiene sentido ya que esta configuración desencadena el problema de desvanecimiento del gradiente .During backpropagation, el ajuste de cada capa se calcula mediante:

$\delta^(l) = h^(l)\,(1 - h^(l))\,\backslash(\cdot)(error\ propagado)$

Dado que la derivada del sigmoide entrega valores muy pequeños (máximo 0.25), al multiplicarlos en cada hacia atrás , los gradentientes (δ) de las primeras capas se vuelven prácticamente cero. Esto evita que sus pesos se actualicen, congelando el aprendizaje.

Además, el conjunto de iris es pequeño(150 muestras) y casi linealmente separable . Agregar 4 capas ocultas introduce una sobre complejidad innecesaria que entorpece la optimización del modelo.